BOOK JOB SCRAPING

เก็บและจับคู่ประกาศงาน พร้อม pipeline เตรียมใบสมัคร โดยการส่งจริงถูกล็อกไว้

System Architecture

รหัสเอกสาร	BJS-DOC-02
ฉบับ	0.1
วันที่	2026-10-08
สถานะ	ร่างเพื่อพิจารณา

เอกสารภายในฉบับร่าง — ใช้ประกอบการพัฒนาและดูแลระบบ

สารบัญ

1. Context diagram

2. Components

3. Tech stack

4. Data stores

5. Integrations

6. Deployment topology

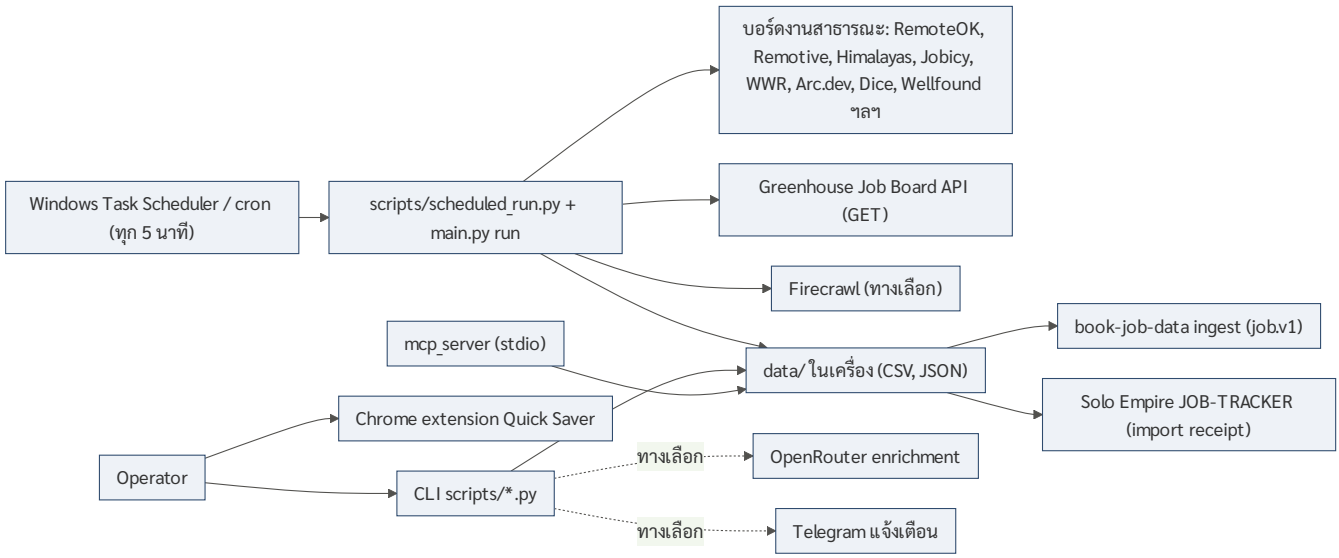
7. ADR สำคัญ

การอนุมัติ

แหล่งข้อมูล

Book Job Scraping — System Architecture

1. Context diagram



2. Components

Component	Path	หน้าที่
Composition root / CLI	`main.py`	คำสั่ง `run [job]`, `status`, `enable`, `disable` ของ scheduler
Core (domain)	`core/models.py`, `core/ports.py`, `core/use_cases.py`, `core/pipeline/` (cleaner, deduplicator), `core/atomic_io.py`, `core/config.py`	model, port, `ScrapeUseCase`, `SearchUseCase`, ทำความสะอาดข้อความไทย, dedup ด้วย content hash, เขียนไฟล์แบบ atomic
Inbound adapters	`adapters/inbound/scheduler_adapter.py`, `mcp_server/server.py`	scheduler จาก YAML (`data/schedule_state.json`), MCP tools
Outbound adapters	`adapters/outbound/engine_adapter.py`, `engines/` (httpx+BS4, Playwright, Selenium, Scrapy, RSS), `exporter_adapter.py`, `storage_adapter.py`	engine และ export JSON/CSV/SQLite/Parquet
Job pipeline scripts	`scripts/scrape_job_postings.py`, `career_discovery.py`, `filter_job_matches.py`, `scrape_job_descriptions.py`, `auto_seed_tracker.py`, `application_review.py`, `multi_resume_manager.py`, `auto_apply.py`, `tailor_resume.py`	capture → match → review → prepare
Policy	`scripts/job_target_policy.py`, `config/job_targeting.yaml`, `scripts/safety.py`, `scripts/http_policy.py`, `scripts/source_coverage.py`	PASS/VERIFY/REJECT, send gate, rate limit/retry, terms registry
Ops	`scripts/scheduled_run.py`, `scripts/file_lock.py`, `scripts/pipeline_health_monitor.py`, `scripts/pipeline_runner.py`, `ops/windows/scheduled-task.ps1`, `setup_cron.sh`, `ops/systemd/*.example`	รันตามตาราง, lock, timeout, health

Component	Path	หน้าที่
Gated senders	`send_application_emails.py`, `email_application.py`, `auto_send_email.py`, `send_followup_emails.py`, `ats_auto_apply.py`	ส่งจริง — ล็อกโดยค่าเริ่มต้น
Secondary lanes	`property/`, `chrome-extension/`, `scripts/import_property_leads.py`, `import_facebook_group_posts.py`, discovery scrapers	รอย้ายไป repo เจ้าของ
Contracts	`contracts/property-capture.v1.json`, `property-demand.v1.json`, `facebook-group-post.v1.json`	schema ของ lane property/social

3. Tech stack

ชั้น	เทคโนโลยี
ภาษา	Python 3.11 (CI)
HTTP/parse	httpx, requests, BeautifulSoup4, lxml, feedparser
Browser	Playwright (Chromium), Selenium
Config	PyYAML (scheduler ในตัว ไม่ใช้ APScheduler)
Optional	scrapy, pydantic, mcp
Extension	Chrome Manifest V3 (`Quick Saver — Jobs & Property Leads` 1.1.0)
Test/lint	pytest, unittest, ruff (เฉพาะ E9/F63/F7/F82)

4. Data stores

ทั้งหมดเป็นไฟล์ใน `data/` (gitignore ยกเว้น `.gitkeep`)

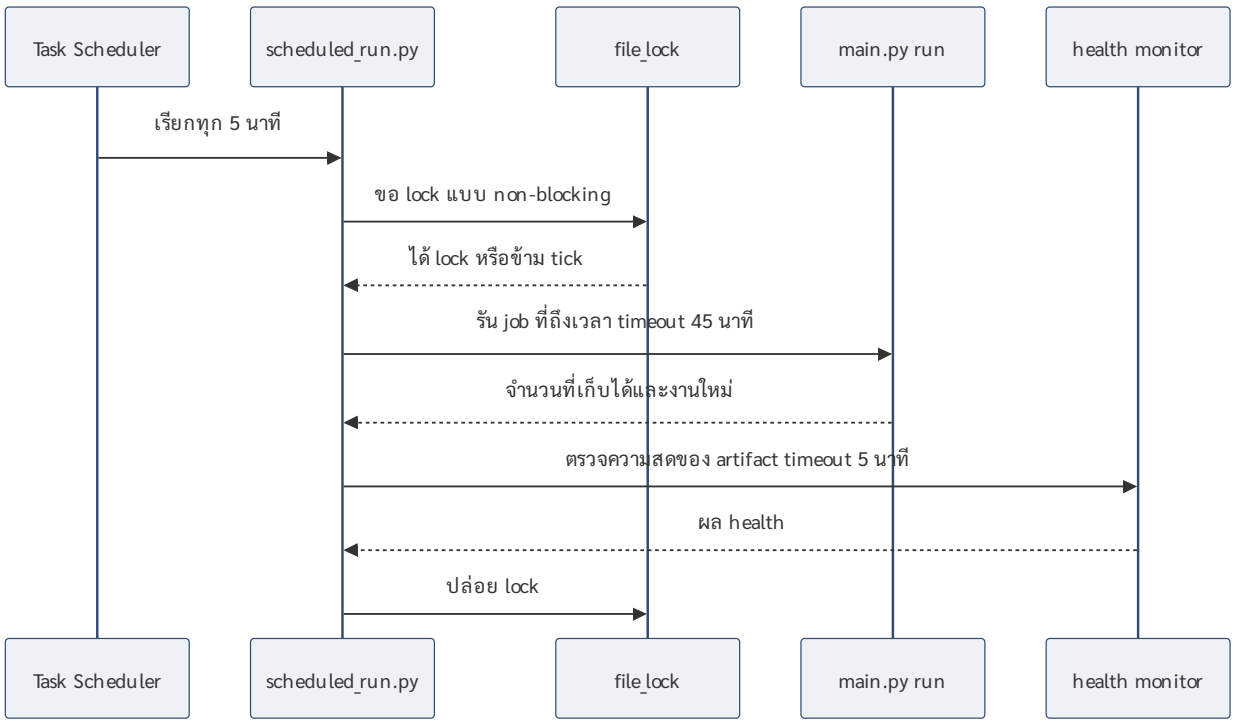
ไฟล์	เนื้อหา	ผู้ใช้ปลายทาง
`job_postings.csv`	snapshot ล่าสุดทุกแหล่ง	match, `book-job-data`
`job_postings_history.csv`	บันทึกงานครั้งแรกที่เห็น	dedup
`career_postings.csv`	capture จาก Greenhouse	match
`matched_jobs.csv`	ผลจัดประเภท + lane/description evidence	review, `book-job-data` (`job_matches`)
`job_descriptions.csv`	รายละเอียดงานอันดับต้น	review
`apply_tracker.csv`	tracker เดิม (`discovered` / `prepared`)	operator
`career-review/<dir>/<JOB_ID>/`	snapshot, checklist ไทย, `verification.json`, `prepared.json`	operator
`confirmed_applications.json`	ใบสมัครที่ยืนยันด้วย receipt + follow-up	JOB-TRACKER
`schedule_state.json`, `cron.log`	สถานะ scheduler, log (rotate ที่ 5 MB)	ops
`briefings/scraper_dashboard.json`	snapshot dashboard	operator

CSV column contract ที่ `book-job-data` ใช้ยังไม่ถูกเขียนใน repo นี้ **[ต้องยืนยัน]** (อ้าง `systems/architecture/job-data-contract-v1.yaml` ใน Solo Empire)

5. Integrations

ระบบ	ทิศทาง	หมายเหตุ
บอร์ดงาน / API สาธารณะ	ขาเข้า	ผ่าน `http_policy.py`: 1 request ต่อ host ต่อ `rate_limit` วินาที, retry ≤ 3 ครั้งบน 429/5xx เคารพ `Retry-After` (สูงสุด 60 วินาที)
Greenhouse Job Board API	ขาเข้า (GET)	ไม่ใช้ API key; ล้มทั้งชุดโดยไม่ทับ capture เดิมเมื่อบอร์ดใดล้ม
Firecrawl	ขาเข้า	ต้องมี `FIRECRAWL_API_KEY`
OpenRouter	ขาออก (ทางเลือก)	enrichment; ไม่จำเป็นต่อ health
Telegram	ขาออก (ทางเลือก)	`--send-telegram` เมื่อได้รับอนุมัติ
`book-job-data`	ไฟล์	`python -m book_job_data.ingest --input .../job_postings.csv`
Solo Empire JOB-TRACKER	ไฟล์	`infra/scripts/opportunities/import_job_applications.py` (metadata เท่านั้น)

5.1 ลำดับ tick ของ scheduler



6. Deployment topology

- เครื่อง operator เครื่องเดียว (Windows ตั้งแต่ 2026-09-30) ใช้ `.venv` ของ repo
- Linux ใช้ `setup_cron.sh` ที่มีความหมายเดียวกัน
- ไม่มี server, container หรือ live URL; MCP server รันแบบ local process

7. ADR สำคัญ

ID	การตัดสินใจ	เหตุผล	หลักฐาน
ADR-01	Hexagonal (ports & adapters)	แยก engine ออกจาก domain	`README.md` §Architecture
ADR-02	Producer เท่านั้น — ไม่เขียน DB ของระบบอื่น, ไม่เรียก API ของ Solo Empire	ขอบเขตชัด, lake-first	`BOUNDARY.md`, `PRODUCT.md`
ADR-03	Live send ต้องผ่าน CLI flag + 2 env unlock + `PASS` + `APPROVED`	ป้องกันการส่งโดยไม่ตั้งใจ	`SAFETY.md`
ADR-04	Contract-first targeting (PASS/VERIFY/REJECT)	กันงานที่ขัดกับสถานะการจ้างงาน	`config/job_targeting.yaml`
ADR-05	Manual ATS submission เป็นเส้นทางที่รองรับ + receipt	automation ข้าม ATS ไม่ได้รับรอง	`CAREER-WORKFLOW.md`
ADR-06	API/RSS ก่อน scraping; ทุกบอร์ดต้องมี terms decision	ความถูกต้องตามกฎ/ToS	`config/source_coverage.yaml`
ADR-07	ย้าย lane ที่ไม่ใช่งานไป repo เจ้าของ	ลดขอบเขต	`BOUNDARY.md` (2026-09-30)

การอนุมัติ

บทบาท	สถานะ	วันที่	ลงนาม
Solution Architect (Book Dev)	รอตรวจ	—	[ต้องยืนยัน]

แหล่งข้อมูล

- `README.md`, `PRODUCT.md`, `BOUNDARY.md`, `SAFETY.md`, `CAREER-WORKFLOW.md`
- `main.py`, `core/`, `adapters/`, `mcp_server/server.py`, `scripts/`, `chrome-extension/manifest.json`
- `config/*.yaml`, `ops/`, `setup_cron.sh`, `requirements.txt`, `.github/workflows/ci.yml`