BOOK JOB SCRAPING

เก็บและจับคู่ประกาศงาน พร้อม pipeline เตรียมใบสมัคร โดยการส่งจริงถูกล็อกไว้

NFR และความปลอดภัย

รหัสเอกสาร	BJS-DOC-03
ฉบับ	0.1
วันที่	2026-10-08
สถานะ	ร่างเพื่อพิจารณา

เอกสารภายในฉบับร่าง — ใช้ประกอบการพัฒนาและดูแลระบบ

สารบัญ

1. NFR พร้อมเป้าหมายที่วัดได้

2. Security controls

3. Privacy / PDPA

4. Observability

5. Backup / DR

การอนุมัติ

แหล่งข้อมูล

Book Job Scraping — NFR และความปลอดภัย

1. NFR พร้อมเป้าหมายที่วัดได้

ID	หมวด	ข้อกำหนด	เป้าหมาย	หลักฐาน
NFR-01	Safety	ไม่มีการส่งอีเมล/ATS โดยไม่ผ่าน gate ทั้งหมด	0 ครั้ง	`test_paths_and_safety.py` (17 test ตาม `PRODUCT.md`)
NFR-02	Freshness	artifact หลัก 4 ไฟล์สด	jobs ทุก 6 ชม.; เกณฑ์อายุตาม `PIPELINE_COLLECTION_MAX_AGE_HOURS`	`pipeline_health_monitor.py`, `test_health_staleness.py`
NFR-03	Reliability	ไม่มี tick ซ้อน; step ที่ค้างถูก kill ทั้ง process tree	collection ≤ 45 นาที, health ≤ 5 นาที, tick exit 124 เมื่อ timeout	`test_scheduled_run.py`, `test_file_lock.py`
NFR-04	Integrity	tick ที่ถูก kill ไม่ทำให้ไฟล์ store ขาด	เขียน temp + `os.replace`	`test_atomic_writes.py`, `test_json_log_recovery.py`
NFR-05	Politeness	ต่อ host ≤ 1 request ต่อ `rate_limit` วินาที; retry ≤ 3	ตาม `config/jobs.yaml` (`job_postings` 2.0 วินาที)	`test_http_policy.py`
NFR-06	Compliance	ไม่มีบอร์ดที่ไม่มี terms decision หรือถูก `blocked` ถูก schedule	0	`source_coverage.py --check`, `test_source_coverage.py`
NFR-07	Log hygiene	`cron.log` rotate	ที่ 5 MB	README §Collection health
NFR-08	Portability	Windows + Linux	CI รัน Windows scheduler tests	`.github/workflows/ci.yml`
NFR-09	Performance	เวลารันต่อ tick	**[ต้องยืนยัน]** ยังไม่มีการวัด	—
NFR-10	Data quality	dedup URL/fingerprint, ตรงกับ host แบบ exact	ไม่มีงานซ้ำใน history	`test_job_history_dedup.py`, git log 2026-09-30

2. Security controls

ID	Control	รายละเอียด
SEC-01	Send gate	ต้องมี `--send` / `--apply` + `BOOK_JOB_LIVE_SEND_ENABLED=1` + `BOOK_JOB_SEND_UNLOCK=I_UNDERSTAND_LIVE_SEND` + `qualification_status=PASS` + `application_readiness=APPROVED`
SEC-02	Preview-only	`ats_auto_apply.py --test` ไม่เปิด Chrome ไม่ submit; `auto_apply.py` เขียนเฉพาะ `prepared`
SEC-03	Immutable prepare	`prepared.json` เก็บ hash ของเอกสาร/candidate/verification; แก้แล้วต้องสร้าง packet ใหม่; verification อายุ ≤ 7 วัน
SEC-04	No runtime pip	สคริปต์ห้าม `pip install` ระหว่างรัน (ใช้ venv + `requirements.txt`)
SEC-05	Secrets	ค่าอยู่ใน secret store ส่วนตัว; ห้าม commit `.env`, tracker CSV, browser profile, PII (`RUNBOOK.md`, `BOUNDARY.md`)
SEC-06	Browser profile	Facebook background capture ใช้ profile แยกนอก repo; ไม่อ่าน cookies/`storage_state`; ไม่ auto-login
SEC-07	Chrome extension	อ่านเฉพาะข้อความที่ render ในแท็บที่ operator กด capture; permission `activeTab`, `storage`, `contextMenus`, `downloads` และ host permission รวม `<all_urls>` **[ต้องยืนยัน]** ความจำเป็นของ `<all_urls>`

ID	Control	รายละเอียด
SEC-08	Social lane gate	`BRAVE_SEARCH_STORAGE_APPROVED`, `PROPERTY_SOCIAL_RETENTION_UNTIL`, `PROPERTY_SOCIAL_TERMS_BASIS_REF` ต้องตั้งก่อนเก็บผลค้นหา; ค่าเริ่มต้นปิด
SEC-09	CI	`permissions: contents: read`; ห้ามตั้ง unlock env ใน CI
SEC-10	Process security	test เฉพาะ (`test_process_security.py`) **[ต้องยืนยัน]** ขอบเขตที่ตรวจ

3. Privacy / PDPA

- ข้อมูลส่วนบุคคลของ operator: resume, cover letter, receipt — เก็บใน path ส่วนตัวที่ไม่ commit; JOB-TRACKER รับเฉพาะ metadata
- ข้อมูลบุคคลที่สาม: อีเมล/contact ของ recruiter (สคริปต์ `find_contact_emails.py`, `extract_hn_emails.py`) และ contact ใน lane property/social — ต้องมีวัตถุประสงค์ ฐานทางกฎหมาย ระยะเวลาเก็บ และทางลบ ตามที่ `SAFETY.md` อ้าง PDPC notice; ปัจจุบัน lane social ปิดและแถวเริ่มที่ `pending` / `not_contacted`
- สถานะการใช้งานจริงของสคริปต์เก็บอีเมล recruiter **[ต้องยืนยัน]**
- `book-job-data` จัด `job.v1` เป็น privacy class internal (`PRODUCT.md`)

4. Observability

สัญญาณ	ที่มา
Health	`pipeline_runner.py --health`, `pipeline_health_monitor.py` (disk, scheduler, ความสด, integration ทางเลือก)
Scheduler	`main.py status`, `data/schedule_state.json`, `cron.log`
ต่อ run	จำนวน request/retry/failure และ scraped/new ที่ scheduler บันทึก
Dashboard	`scripts/scraper_dashboard.py` → `data/briefings/scraper_dashboard.json` (08:15, 11:15, 20:15)
Alert	Telegram (ทางเลือก, ต้องอนุมัติ)

5. Backup / DR

- `scripts/pipeline_backup.py` และ `pipeline_recovery.py` มีอยู่ **[ต้องยืนยัน]** ว่าถูกใช้ตามตารางหรือไม่
- `data/` เป็น runtime ที่ gitignore: สูญหายได้ถ้าเครื่องเสีย ส่วนที่สำคัญที่สุดคือ `confirmed_applications.json` และ `career-review/` (หลักฐานการสมัคร)
- RPO/RTO ไม่ได้กำหนด **[ต้องยืนยัน]**; ข้อเสนอ **[สมมติฐาน]** สำรอง `data/confirmed_applications.json` และ `career-review/` รายวันไปยัง backup ส่วนตัว
- Capture ส่วนใหญ่สร้างใหม่ได้จากการรัน scraper (ยกเว้นงานที่หมดอายุไปแล้ว)

การอนุมัติ

บทบาท	สถานะ	วันที่	ลงนาม
Solution Architect (Book Dev)	รอตรวจ	—	[ต้องยืนยัน]
Security reviewer	รอตรวจ	—	[ต้องยืนยัน]

แหล่งข้อมูล

- `SAFETY.md`, `CAREER-WORKFLOW.md`, `PRODUCT.md`, `BOUNDARY.md`, `RUNBOOK.md`, `README.md`
- `scripts/safety.py`, `scripts/http_policy.py`, `scripts/scheduled_run.py`, `scripts/file_lock.py`
- `chrome-extension/manifest.json`, `.github/workflows/ci.yml`, `tests/`