BOOK JOB SCRAPING

เก็บและจับคู่ประกาศงาน พร้อม pipeline เตรียมใบสมัคร โดยการส่งจริงถูกล็อกไว้

Runbook การติดตั้งและดูแลระบบ

รหัสเอกสาร	BJS-DOC-04
ฉบับ	0.1
วันที่	2026-10-08
สถานะ	ร่างเพื่อพิจารณา

เอกสารภายในฉบับร่าง — ใช้ประกอบการพัฒนาและดูแลระบบ

สารบัญ

1. Environments

2. ติดตั้ง / build

3. Config (ชื่อตัวแปรเท่านั้น)

4. รันและติดตั้ง scheduler

5. Health check

6. Rollback

7. Incident / troubleshooting

8. Backup / restore

การอนุมัติ

แหล่งข้อมูล

Book Job Scraping — Runbook การติดตั้งและดูแลระบบ

> สรุปจาก `RUNBOOK.md`, `README.md`, `SAFETY.md` และ `CAREER-WORKFLOW.md` ถ้าขัดกัน ให้ `SAFETY.md` มีผลเหนือกว่า

1. Environments

Env	ใช้ทำอะไร	สถานะ
Windows host ของ operator	scheduler หลัก (`ops/windows/scheduled-task.ps1`)	ใช้งานตั้งแต่ 2026-09-30
Linux	`setup_cron.sh` (ความหมายเดียวกัน)	สำรอง
CI	Ubuntu (ruff + pytest) และ Windows (scheduler tests)	ใช้งาน
Production server	ไม่มี	—

2. ติดตั้ง / build

```
python3 -m venv .venv && . .venv/bin/activate
pip install -r requirements.txt
playwright install chromium          # □□□□□ job □□□□□□□ render JS
.venv/bin/python scripts/pipeline_runner.py --dry-run
```

ไม่มีขั้น build; สคริปต์ห้าม `pip install` ระหว่างรัน

3. Config (ชื่อตัวแปรเท่านั้น)

กลุ่ม	ตัวแปร
Path	`BOOK_JOB_SCRAPING_ROOT`, `PIPELINE_DATA_DIR`, `BOOK_JOB_SCRAPING_DATA_DIR` (ฝั่ง `book-job-data`)
Health	`PIPELINE_HEALTH_MODE`, `PIPELINE_COLLECTION_MAX_AGE_HOURS`, `PIPELINE_REQUIRE_OPENROUTER`, `PIPELINE_REQUIRE_TELEGRAM`
Politeness	`JOB_SCRAPE_MIN_INTERVAL`
Capture	`FIRECRAWL_API_KEY`, `JINA_API_KEY`
AI (ทางเลือก)	`OPENROUTER_API_KEY`, `AI_MODEL`
แจ้งเตือน (ทางเลือก)	`TELEGRAM_BOT_TOKEN`, `TELEGRAM_CHAT_ID`, `TELEGRAM_HEALTH_BOT_TOKEN` และ `TELEGRAM_*` อื่น
Send gate (ห้ามตั้งโดยไม่มีคำสั่ง)	`BOOK_JOB_LIVE_SEND_ENABLED`, `BOOK_JOB_SEND_UNLOCK`
Social/property gate (ค่าเริ่มต้นปิด)	`BRAVE_SEARCH_API_KEY`, `BRAVE_SEARCH_STORAGE_APPROVED`, `PROPERTY_SOCIAL_RETENTION_UNTIL`, `PROPERTY_SOCIAL_TERMS_BASIS_REF`, `TGCONDO_CONTACT_STORAGE_APPROVED`, `TGCONDO_RETENTION_UNTIL`, `TGCONDO_TERMS_BASIS_REF`
Integration อื่นในสคริปต์	`GITHUB_TOKEN`, `GOOGLE_CLIENT_ID`, `GOOGLE_CLIENT_SECRET`, `GOOGLE_REFRESH_TOKEN`, `GOOGLE_CALENDAR_ID`, `CLOUDFLARE_ACCOUNT_ID`, `CLOUDFLARE_API_TOKEN`, `LEANTIME_URL`, `LEANTIME_API_KEY` **[ต้องยืนยัน]** ว่ายังใช้

ค่าจริงอยู่ใน secret store ส่วนตัว; ห้าม commit `.env`, tracker CSV, browser profile หรือ PII

4. รันและติดตั้ง scheduler

```
.venv/bin/python main.py run                # □□□ job □□□□□□□□□□
.venv/bin/python main.py run job_postings   # □□□ job □□□□□
.venv/bin/python main.py status
bash setup_cron.sh install | status | remove  # Linux
.\ops\windows\scheduled-task.ps1 install     # Windows (PowerShell)
```

Windows: ตั้ง `PYTHONUTF8=1` เมื่อรันเอง (scheduled runner ตั้งให้แล้ว)

5. Health check

```
.venv/bin/python scripts/pipeline_runner.py --health
.venv/bin/python scripts/pipeline_health_monitor.py
.venv/bin/python scripts/source_coverage.py --check
```

เขียว = `job_postings.csv`, `matched_jobs.csv`, `apply_tracker.csv`, `job_descriptions.csv` สดทั้งหมด

6. Rollback

1. หยุด scheduler ของ repo นี้: `bash setup_cron.sh remove` หรือ uninstall task บน Windows **[ต้องยืนยัน]** คำสั่ง uninstall ของ `scheduled-task.ps1`
2. เก็บ `data/` ไว้ตรวจ ห้ามลบ
3. ถอย commit ที่มีปัญหาแล้วรัน `pytest -q`
4. ปิด job ที่เสียด้วย `main.py disable <job>` แทนการแก้ด่วน
5. ห้ามเปิด live send/apply ระหว่าง rollback

7. Incident / troubleshooting

อาการ	ตรวจ	แก้
Health แดง: artifact เก่า	`main.py status`, `cron.log`	รัน `main.py run job_postings` เอง; ดู error ของบอร์ด
บอร์ดตอบ 403/Cloudflare	log ของ job	disable job; บันทึกใน `config/source_coverage.yaml`
Tick ไม่รัน	lock ค้าง	ตรวจว่ามี process ค้าง; tick ใหม่จะข้ามถ้ายังถือ lock
Tick exit 124	step เกิน timeout	ดู job ที่ช้า ลด scope หรือ disable
`Missing dependency`	venv ไม่ครบ	`pip install -r requirements.txt` ใน `.venv`
JSON store อ่านไม่ได้	ไฟล์เสีย	ระบบเก็บไฟล์เดิมไว้ไม่ทับ (fix 2026-09-30); ตรวจแล้วกู้เอง

8. Backup / restore

- ไฟล์สำคัญ: `data/confirmed_applications.json`, `data/career-review/`, `data/apply_tracker.csv`, `config/`
- มี `scripts/pipeline_backup.py` / `pipeline_recovery.py` **[ต้องยืนยัน]** วิธีใช้และปลายทาง

- Restore: คัดลอกกลับ `data/` แล้วรัน health check; receipt ที่ import เข้า JOB-TRACKER แล้วยังอยู่ใน Solo Empire

การอนุมัติ

บทบาท	สถานะ	วันที่	ลงนาม
Operator (Book Dev)	รอตรวจ	—	[ต้องยืนยัน]

แหล่งข้อมูล

- `RUNBOOK.md`, `README.md` (Quick Start, Collection health), `SAFETY.md`, `CAREER-WORKFLOW.md`
- `main.py`, `setup_cron.sh`, `ops/windows/scheduled-task.ps1`, `scripts/` (env var names จากการค้นในโค้ด)